

Algoritmo de Colonias de Hongos: Un Enfoque Bio Inspirado para la Optimización

Kevin García, Isabella Ardila & Camilo López

April 25, 2024

1 Introducción

El Algoritmo de Colonias de Hongos (FCA) es una técnica de optimización bioinspirada que emula el comportamiento de las colonias de hongos para resolver problemas de optimización. Inspirado en la búsqueda y optimización del crecimiento de los hongos en su entorno natural, este algoritmo encuentra aplicaciones en diversos campos como ingeniería, logística, telecomunicaciones y biología. Desarrollado por Farid Alizadeh en 2003, el FCA utiliza conceptos como la emisión de esporas, la absorción de nutrientes y la competencia por recursos. En este documento, nos enfocaremos en aplicar el FCA para la optimización de rutas de distribución en una red logística, buscando mejorar la eficiencia operativa y reducir costos. Este método destaca por su capacidad de exploración, adaptabilidad a cambios y la obtención de soluciones de alta calidad en entornos complejos.

2 ¿Qué es?

El Algoritmo de Colonias de Hongos (Fungal Colony Algorithm, FCA) es un método de optimización bioinspirado que se basa en el comportamiento y la estructura de las colonias de hongos para resolver problemas de optimización. Este algoritmo se inspira en la forma en que los hongos buscan y optimizan su crecimiento y desarrollo en su entorno natural.

3 ¿Para qué se usa?

El Algoritmo de Colonias de Hongos se utiliza para resolver una amplia gama de problemas de optimización combinatoria y continua en diversos campos, incluyendo ingeniería, logística, telecomunicaciones, biología, entre otros. Algunas aplicaciones comunes incluyen la optimización de rutas, la planificación de tareas, la asignación de recursos y la optimización de funciones matemáticas.

4 ¿Cómo se desarrolló?

El Algoritmo de Colonias de Hongos fue propuesto por primera vez por Farid Alizadeh en 2003. Se basa en la observación del comportamiento de las colonias de hongos en la naturaleza, donde los hongos utilizan procesos de crecimiento y exploración para encontrar fuentes de alimento y optimizar su crecimiento en un entorno competitivo. El algoritmo modela este comportamiento utilizando conceptos como la emisión de esporas, la absorción de nutrientes, la comunicación entre hongos y la competencia por recursos.

El desarrollo del algoritmo implica la definición de reglas y parámetros que gobiernan el comportamiento de las "células" virtuales en el espacio de búsqueda del problema. Estas células representan posibles soluciones y se mueven a través del espacio de búsqueda utilizando estrategias de exploración y explotación inspiradas en el comportamiento de las colonias de hongos reales. La optimización se logra mediante la evolución y la adaptación de las células a lo largo de varias generaciones.

5 Problema a Desarrollar: Optimización de Rutas de Distribución Utilizando el Algoritmo de Colonias de Hongos

En este documento, nos enfocaremos en aplicar el Algoritmo de Colonias de Hongos para resolver el problema de optimización de rutas de distribución en una red logística. El objetivo es encontrar las rutas más eficientes para entregar productos a diferentes ubicaciones, minimizando la distancia recorrida por los vehículos y cumpliendo con restricciones de tiempo y recursos.

6 Descripción del Problema: Optimización de rutas

“La optimización de rutas es el proceso por el cual se logra organizar la distribución de las entregas o repartos al cliente.” (QuadMinds,2020)

En una empresa de distribución logística, se enfrenta el desafío de optimizar las rutas de entrega de productos a diferentes ubicaciones. Esta empresa dispone de una flota de vehículos para realizar las entregas y necesita planificar las rutas de manera eficiente para minimizar los costos operativos, como el consumo de combustible y el tiempo de viaje, al mismo tiempo que se cumple con las restricciones de tiempo y recursos.

Puntos de Entrega. Ubicaciones y demandas de Productos: Cada ubicación puede tener una demanda específica de productos. Es importante considerar estas demandas al planificar las rutas para asegurarse de que los vehículos lleven la cantidad adecuada de productos a cada destino.

Flota de Vehículos. Capacidad y Características: Cada vehículo en la flota tiene una capacidad máxima de carga y características únicas, como el consumo de combustible, la velocidad máxima y la autonomía. Estas características deben tenerse en cuenta al asignar vehículos a rutas específicas para maximizar la eficiencia operativa.

Restricciones de Tiempo: Ventanas de Tiempo: Además de las ventanas de tiempo para las entregas en los puntos de entrega individuales, también puede haber restricciones de tiempo para la duración total de las rutas. Por ejemplo, es posible que se requiere que todas las entregas se realicen dentro de un cierto período de tiempo para evitar retrasos excesivos.

Costos Operativos: Consumo de Combustible y Desgaste de Vehículos: Minimizar la distancia total recorrida por la flota de vehículos no solo reduce los costos de combustible, sino que también ayuda a minimizar el desgaste de los vehículos, lo que a su vez reduce los costos de mantenimiento a largo plazo.

Tiempo de Viaje y Eficiencia:

Reducir el tiempo de viaje total también contribuye a la eficiencia operativa general de la empresa, permitiendo una entrega más rápida de productos a los clientes y una mejor planificación de recursos.

7 Objetivo de la Optimización:

El objetivo final de la optimización es encontrar un conjunto de rutas de distribución que minimicen la distancia total recorrida por la flota de vehículos, cumpliendo al mismo tiempo con todas las restricciones de tiempo y recursos establecidas. Esto garantizará una operación logística eficiente y rentable para la empresa de distribución.

8 Aplicación del Algoritmo de Colonias de Hongos:

El algoritmo de Colonias de Hongos (FCA) nos ayuda a resolver nuestro objetivo que es la optimización de rutas de distribución en la empresa de logística para minimizar la distancia total recorrida por un conjunto de camiones que visitan un conjunto de puntos de entrega.

Esto se puede resolver, pero tenemos ciertas restricciones como:

- Cada punto de entrega debe visitarse una vez.
- La capacidad de cada camión es limitada.
- La duración de cada viaje no debe superar un límite establecido

Para lograrlo vamos usar las diferentes fases del algoritmo MRO teniendo nuestros parametros M , que es el número de hongos y N el número de distribución de esporas por los hongos padres.

Fase 1 - Inicialización: Para solucionar la optimización de rutas usaremos grafos para representar las posibles soluciones, la inicialización consiste en establecer todas las posibles rutas en una red de puntos de entrega, pero dependerán de la cantidad de hongos padre (colonias) se deseen utilizar.

¿Pero qué significa ir desde el punto A hasta el punto B? Recordemos que nuestro problema busca minimizar la distancia total recorrida por cada camión que tiene que pasar por ciertos puntos de entrega, entonces el **parámetro M (Número de colonias de hongos)** se puede interpretar como la cantidad de posibles soluciones al problema, que en este caso serían **todas las posibles rutas para ir desde un punto A hasta un punto B**. Dado que las rutas se pueden representar como caminos en un grafo, donde los nodos son los puntos de interés (ubicaciones) y las aristas son los tramos de carretera o enlaces entre ellos, el número total de rutas posibles puede ser muy grande y puede modelarse como un problema de combinatoria.

Entonces, sí, cada colonia de hongos en el algoritmo representaría una posible solución (una ruta específica) que va desde el punto de partida hasta el destino. Y al ajustar el parámetro M , estamos controlando la cantidad de posibles rutas que el algoritmo considerará durante el proceso de optimización. Cuantas más colonias (posibles rutas) haya, más

diversidad y exploración habrá en la búsqueda de la mejor ruta posible.

Cuando hablamos de buscar todas las posibles soluciones para un parámetro M dado, nos referimos a que el algoritmo considerará un conjunto finito de soluciones igual al número de colonias de hongos especificado por ese parámetro.

Por ejemplo, si configuramos $M = 10$, entonces el algoritmo generará y evaluará 10 posibles soluciones diferentes, cada una representada por una colonia de hongos. Cada una de estas soluciones potenciales representa una ruta específica desde el punto de partida hasta el destino.

Es importante destacar que el algoritmo no está buscando explícitamente todas las posibles soluciones en el espacio de búsqueda, ya que eso podría no ser factible computacionalmente para problemas grandes. En cambio, el algoritmo utiliza un enfoque heurístico para explorar un subconjunto representativo de soluciones en función del número de colonias de hongos especificado por el parámetro M . Este enfoque permite una exploración más eficiente y efectiva del espacio de soluciones posibles.

Ahora bien, el parámetro N , que representa el número de esporas en la inicialización de cada colonia, se relaciona con la cantidad de modificaciones que se consideran para cada posible ruta de entrega. Imaginemos que cada ruta principal es como un camino inicial desde el punto de partida hasta el destino.

Cuando generamos esporas, estamos creando versiones modificadas de estas rutas principales. Cada espora representa una pequeña modificación en la ruta principal, como tomar un camino diferente, cambiar el orden de las paradas, o ajustar los horarios de entrega.

Entonces, si tenemos un mayor número de esporas (un valor más alto de N), estamos considerando más modificaciones para cada ruta principal. Esto nos permite explorar una variedad de posibles rutas y encontrar soluciones óptimas en costos, tiempos de entrega, etc.

El parámetro N controla cuántas versiones modificadas de cada ruta principal consideramos al principio. Un valor más alto de N significa una exploración más amplia y detallada del espacio de soluciones, pero también puede aumentar el costo computacional del algoritmo.

En nuestro problema es importante utilizar la función de fitness se diseña para evaluar qué tan efectiva es una ruta específica en términos de los objetivos y restricciones del problema. Esta función puede tener en cuenta diversos factores relevantes para la logística, como el tiempo de entrega, la distancia recorrida, los costos asociados (como el costo de combustible o los costos de mano de obra), las restricciones de capacidad de los vehículos, los tiempos de espera en las paradas, entre otros.

La función de fitness puede definirse de diferentes maneras según las necesidades específicas del problema y los criterios que deseamos optimizar. Por ejemplo, una posible formulación de la función de fitness para la optimización de rutas logísticas podría ser la suma ponderada del tiempo de viaje entre cada par de ubicaciones en la ruta, más cualquier otro factor que se considere importante, como los costos asociados con ciertas rutas o las penalizaciones por violar restricciones de tiempo o capacidad.

Durante la ejecución del algoritmo, cada posible solución (representada por un hongo padre o una espora) se evalúa utilizando esta función de fitness. Cuanto mejor sea la solución en términos de la función de fitness, mayor será su valor de aptitud. El algoritmo usa estos valores de aptitud para seleccionar las soluciones que se reproducirán y cuáles se mantendrán en la próxima generación, para encontrar soluciones que optimicen la función de fitness y mejoren la eficiencia y efectividad de las rutas logísticas.

Fase 2 - Búsqueda local (Reproducción local):

Parametros: r - Radio de la búsqueda/reproducción local

c - Decidir si una colonia se elimina o no

Generación de nuevas soluciones (esporas):

$$X_{ij} = X_i^{parent} + Rand(-r, r) \quad (1)$$

- X_{ij} : Posición de la espota j en la colonia i
- X_i^{parent} : Posición de la ruta principal de la colonia i.
- r: Radio de búsqueda local alrededor de la ruta principal actual

Interpretación: En esta fase, cada colonia de hongos (representando una solución) genera N nuevas soluciones (esporas) en el vecindario de su ruta principal actual.

Cada nueva solución se obtiene sumando un desplazamiento aleatorio alrededor de la posición de la ruta principal actual, lo que permite explorar diferentes posibles rutas en el vecindario.

1. X_{ij} : Este término representa la posición de una nueva espota, es decir, una posible solución alternativa dentro del espacio de búsqueda local. En el contexto de nuestro problema cada X_{ij} podría representar una ruta potencialmente diferente que difiere
2. Ligeramente de la ruta principal (representada por $X_{parenti}$). Por ejemplo, X_{ij} podría representar una ruta que toma un camino alternativo en una intersección o realiza una entrega en un orden diferente.

3. X_i^{parent} : Este término representa la posición del hongo padre, que a su vez representa la solución o la ruta principales de una colonia de hongos. En nuestro problema, $X_{parenti}$ representa la ruta principal que se está explorando en la búsqueda local. Es la base desde la cual se generan las esporas (nuevas soluciones potenciales).
4. $Rand(-r,r)$ genera valores aleatorios en un radio de búsqueda local para introducir variabilidad en la optimización de rutas. Esto ayuda a encontrar soluciones cercanas a la ruta principal y evita quedar atrapado en óptimos locales subóptimos. El radio de búsqueda determina qué tan lejos exploramos nuevas soluciones alrededor de la ruta actual. Por ejemplo, un radio de 1 kilómetro significa que las nuevas soluciones estarán dentro de ese radio alrededor de cada punto de la ruta principal. Esto nos permite explorar diferentes variaciones de la ruta, como caminos alternativos, cambios en el orden de las paradas, etc., en un área local.

El parámetro c en el algoritmo FCA se utiliza para decidir si se elimina o no una colonia (o conjunto de soluciones) en función de su calidad en relación con el resto de las colonias.

El parámetro c se utiliza junto con el promedio de aptitud de la colonia y el promedio total de aptitud de todas las colonias en la iteración actual. La condición de eliminación se define de la siguiente manera:

$$Avg(i) + Tavg * c < Tavg \quad (2)$$

Donde:

- $Avg(i)$ es el promedio de aptitud de la colonia i .
- $Tavg$ es el promedio total de aptitud de todas las colonias en la iteración actual
- c es el parámetro que controla la eliminación de colonias.

Esta condición compara el promedio de aptitud de una colonia con un factor c añadido, con el promedio total de todas las colonias. Si el promedio de la colonia es menor que el promedio total, se considera de baja calidad y puede ser eliminada. Esto ayuda a centrarse en soluciones de mayor calidad y mejorar la eficiencia de la búsqueda.

En el contexto de nuestro problema, asociamos el parámetro c con la capacidad de adaptación de cada ruta propuesta a las condiciones específicas del problema. Aquí exponemos una manera de relacionarlo con nuestro caso:

Supongamos que se han generado varias rutas alternativas para la entrega de productos, cada una representada por una colonia en el algoritmo. Cada ruta tiene asociada una cierta aptitud que representa su calidad en términos de eficiencia, costo, tiempo de entrega, etc.

El parámetro c podría interpretarse como un umbral que determina si una ruta en particular es lo suficientemente competitiva en comparación con otras rutas. Por ejemplo, podríamos establecer que si la aptitud promedio de una ruta (representada por $Avg(i)$) es significativamente menor que la aptitud promedio de todas las rutas (representada por $Tavg$), multiplicada por c , entonces esa ruta se considera de baja calidad y podría ser eliminada.

En otras palabras, si una ruta tiene un desempeño sustancialmente peor que el promedio general de todas las rutas, según el valor de c , podríamos decidir eliminar esa ruta para enfocar nuestros esfuerzos en rutas más prometedoras y mejorar así la calidad general del conjunto de soluciones.

Entonces, el parámetro c nos permite controlar cuánto queremos mantener la diversidad en las soluciones propuestas. Si c es bajo, se eliminarán más colonias y el algoritmo tenderá a explorar nuevas soluciones con mayor frecuencia. Por otro lado, si c es alto, se conservarán más colonias y el algoritmo tenderá a explotar soluciones conocidas con mayor frecuencia. Esto nos brinda flexibilidad para adaptar el algoritmo a las necesidades específicas del problema de optimización de rutas logísticas que estamos abordando.

$$X_{ij} = X_i^{parent} + Mov_j^{wind} \quad (3)$$

Interpretación:

- Genera nuevas posibles rutas de entrega en el vecindario de la ruta principal actual, teniendo en cuenta tanto las soluciones actuales como la influencia global adicional para mejorar su eficiencia
- X_{ij} : Representa una posible ruta alternativa para la entrega de los productos desde la ubicación i hasta la ubicación j . Ayudándonos a encontrar la mejor ruta posible, teniendo menor tiempo a la hora de entre y menos recursos consumidos.
- X_i^{parent} : Este término representa la posición del hongo padre, que a su vez representa la solución o la ruta principales de una colonia de hongos. En nuestro problema, representa la ruta principal que se está explorando en la búsqueda local. Es la base desde la cual se generan las esporas (nuevas soluciones potenciales).
- Mov_j^{wind} : Este término representa la posición del hongo padre, que a su vez representa la solución o la ruta principales de una colonia de hongos. En nuestro problema, representa la ruta principal que se está explorando en la búsqueda local. Es la base desde la cual se generan las esporas (nuevas soluciones potenciales).

Se puede ejemplificar dentro de nuestro problema como durante la fase de búsqueda local se generan nuevas soluciones (esporas) en el vecindario de las soluciones principales actuales. En este contexto, X_{ij} representa una posible solución alternativa dentro de este

vecindario, que se diferencia ligeramente de la ruta principal actual (X_i^{parent}). Esta diferencia puede manifestarse en cambios como tomar caminos alternativos, modificar el orden de las entregas o ajustar los horarios de entrega para cumplir con las restricciones de tiempo y recursos.

Este Mov_j^{wind} introduce variabilidad y exploración en la búsqueda local al permitir que las nuevas esporas (posibles rutas alternativas) se generen en ubicaciones dentro de un cierto radio alrededor de la ruta principal actual. En otras palabras, el movimiento del viento permite que las posibles rutas se desplacen sutilmente en diferentes direcciones, lo que facilita la exploración de diversas variaciones de la ruta principal.

Este proceso es fundamental porque ayuda a evitar quedar atrapado en óptimos locales subóptimos. Al introducir esta variabilidad, el algoritmo puede explorar de manera más amplia el espacio de búsqueda y descubrir soluciones potencialmente mejores que no serían alcanzadas si el algoritmo se limitara estrictamente a la vecindad de la ruta principal actual.

Fase 3: Búsqueda global (Búsqueda global con viento)

$$Mov_j^{wind} = (X_i^* - X_k^*) * (\frac{Avg(i)}{T_{avg}})^{-m} * Rand(-\alpha, \alpha) * rs + Rand(-r, r) \quad (4)$$

Interpretación:

- Esta ecuación calcula el movimiento inducido por el viento en la dimensión j del espacio de búsqueda.
- X_i^* y X_k^* representan las mejores soluciones en las colonias i y k respectivamente, actuando como puntos de referencia para el movimiento del viento.
- $Avg(i)$ es el promedio de las medidas de aptitud de todas las soluciones en la colonia i, y T_{avg} es el promedio global de todas las medidas de aptitud.
- m controla la magnitud del movimiento del viento.
- $Rand(-\alpha, \alpha)$ y $Rand(r, r)$ introducen componentes aleatorios en la dirección y magnitud del movimiento del viento.
- rs y α son parámetros que controlan la escala y magnitud máxima del componente aleatorio del movimiento del viento, respectivamente.

Las mejores soluciones locales en cada colonia representan las rutas más prometedoras hasta ahora, mientras que el promedio global de aptitudes da una referencia general del rendimiento de todas las rutas.

$(X_i - X_k)x(Avg(i)/Tavg)$, describe la dirección y magnitud del movimiento del viento se basan en la diferencia entre las mejores soluciones locales y el promedio global de aptitudes. Esto significa que el viento impulsa el ajuste de las rutas hacia áreas donde las soluciones locales son más ventajosas en comparación con el promedio global. En términos prácticos, esto implica dirigir las rutas hacia aquellas que muestran un mejor desempeño en eficiencia, costo o tiempo de entrega. Siendo más específica notamos que, Por otro lado, $Avg(i)$ representa el promedio de las medidas de aptitud de todas las soluciones en la colonia i , mientras que $Tavg$ es el promedio global de todas las medidas de aptitud.

- $m \times \text{Rand}(-s, s) \times rs + \text{Rand}(-r, r)$, introduce componentes aleatorios en la dirección y magnitud del movimiento del viento esto para explorar diversas áreas del espacio de búsqueda de manera controlada. Esta variabilidad es fundamental para evitar quedar atrapado en soluciones locales subóptimas y garantizar una búsqueda amplia, pero no quiere decir que no sea controlada. Por el contrario, es exhaustiva hablando de las rutas de distribución óptimas.

Algoritmo MRO:

- **Inialización:** La fase en la que se generan aleatoriamente las soluciones iniciales (colonias de hongos) en el espacio de búsqueda.
- **Búsqueda Local (Reproducción Local):** La fase en la que se generan nuevas soluciones (esporas) en el vecindario de las soluciones principales actuales.
- **Búsqueda Global (Búsqueda Global con Viento):** La fase en la que se introduce el viento como una fuerza global adicional que afecta a todas las soluciones en todas las colonias.

Problema de Optimización de Rutas:

- **Soluciones Iniciales:** Representan las rutas iniciales generadas aleatoriamente para los vehículos.
- **Nuevas Soluciones (Esporas):** Representan las posibles rutas que se generan cerca de las rutas principales actuales, explorando el vecindario del espacio de búsqueda.
- **Viento:** Representa la influencia adicional que afecta a las rutas, moviéndolas hacia regiones potencialmente prometedoras del espacio de búsqueda.

Comentarios adicionales:

- Cada fase del algoritmo MRO se construye utilizando las ecuaciones propuestas, adaptadas al contexto del problema de optimización de rutas.
- Las soluciones generadas y modificadas en cada fase representan posibles rutas que deben ser evaluadas en términos de su calidad, generalmente mediante una función de aptitud que refleje el objetivo de optimización del problema de rutas (por ejemplo, minimizar la distancia total recorrida).

- La búsqueda se repite durante múltiples iteraciones hasta que se cumpla un criterio de terminación predefinido, como un número máximo de iteraciones o una mejora mínima en la mejor solución encontrada.
- El algoritmo MRO utiliza tanto la exploración global (mediante el viento) como la exploración local (mediante la generación de nuevas soluciones en el vecindario de las soluciones principales actuales) para buscar soluciones óptimas o subóptimas para el problema de optimización de rutas.

Exploración del Espacio de Soluciones: FCA es capaz de explorar de manera eficiente un amplio espacio de soluciones. En el contexto de la planificación de rutas de distribución, esto significa que puede considerar una variedad de posibles rutas para cada vehículo, teniendo en cuenta las diferentes combinaciones de puntos de entrega y ventanas de tiempo, y evaluar su viabilidad y eficiencia.

Función Objetivo Para Minimizar Tiempo y Distancia.

$$\text{Minimize } \sum_{i=1}^V \sum_{j=1}^{N_i-1} (\text{dist}(c_{ij}, c_{i(j+1)}) / \text{velocidad}) \quad (5)$$

Donde:

- V es el número de vehículos disponibles.
- N_i es el número de clientes atendidos por el vehículo i .
- c_{ij} es el cliente j atendido por el vehículo i
- $\text{dist}(x,y)$ es la distancia euclidiana entre los puntos x e y .
- velocidad es la velocidad promedio del vehículo, que se utiliza para convertir la distancia en tiempo.

Esta función objetivo calcula el tiempo total de viaje para todos los vehículos para satisfacer la demanda de los clientes. Primero, calcula la distancia entre cada par de clientes consecutivos atendidos por el mismo vehículo y luego divide esta distancia por la velocidad promedio del vehículo para obtener el tiempo de viaje. La función objetivo busca minimizar la suma total de los tiempos de viaje de todos los vehículos.

Esta función es adecuada si la principal preocupación es minimizar el tiempo y la distancia total recorrida por los vehículos, sin considerar otras consideraciones como la capacidad del vehículo o las ventanas de tiempo de los clientes.

Adaptabilidad a Cambios: FCA es adaptable a cambios en las condiciones del problema. Esto es útil en el contexto de la distribución logística, donde pueden surgir cambios repentinos, como nuevas ubicaciones de entrega, modificaciones en las demandas de productos o cambios en las restricciones de tiempo. FCA puede ajustar rápidamente las soluciones existentes para adaptarse a estos cambios y encontrar nuevas soluciones óptimas.

Optimización de Rutas: FCA puede encontrar soluciones de alta calidad para el problema de optimización de rutas, minimizando la distancia total recorrida por la flota de vehículos mientras se cumplen todas las restricciones de tiempo y recursos. Utilizando principios inspirados en el comportamiento de las colonias de hongos, el algoritmo puede evolucionar y adaptar las rutas de distribución para maximizar la eficiencia operativa.

Balance entre Eficiencia y Complejidad: FCA puede encontrar un equilibrio entre la eficiencia de las rutas y la complejidad computacional del problema. Esto significa que puede encontrar soluciones óptimas o cercanas a óptimas en un tiempo razonable, lo que es crucial en entornos logísticos donde se deben tomar decisiones rápidas y eficientes para mantener la operación en funcionamiento. (OpenAI, 2024)

Chat GPT se utilizó, para profundizar y aclarar el funcionamiento del algoritmo para empezar a dar aplicación, donde se le preguntó "¿Cómo funciona el FCA en detalle?" el día 10 de Marzo de 2024.

References

- [1] Bidar, M. (2018).

```
Randomly generate M parent mushrooms
For i = 1: M
    For j = 1: N
         $X_{ij} = X_i^{parent} + \overrightarrow{Rand(-r, r)}$ 
        //generate spore j for colony i
    Endfor
Endfor
For i = 1: M
    Calculate  $F(X_i^{parent})$ 
    Calculate Avg(i)
    //average fitness of colony i
    Select best agent  $X_i^*$  in colony i
     $X_i^{parent} = X_i^*$ 
Endfor
Calculate  $T_{avg}$ 
//total average fitness of all colonies
While (termination condition is not met)
    For i = 1: M
        If  $Avg(i) + \frac{T_{Avg}}{c} < T_{Avg}$  then
            For k = 1: M
                If  $F(X_i^*) < F(X_k^*)$  then
                    For j = 1: N
                         $X_{ij} = X_i^{parent} + \overrightarrow{Mov_j^{wind}}$ 
                        //move spore  $X_{ij}$  with artificial wind
                    Endfor
                    Select best agent  $X_i^*$  in colony i
                     $X_i^{parent} = X_i^*$ 
                    Update global best solution
                Endif
            Endfor
        Endif
        For j = 1: N
             $X_{ij} = X_i^{parent} + \overrightarrow{Rand(-r, r)}$ 
        Endfor
        Calculate Avg(i)
        Select best agent  $X_i^*$  in colony i
         $X_i^{parent} = X_i^*$ 
        Update global best solution
    Endfor
    Calculate  $T_{avg}$ 
Endwhile
Return global best solution
```

Figure 1: Enter Caption

9 Funcionamiento Algoritmo de Colonias de Hongos:

- **Inicialización:** Se inicializa una población de "colonias" virtuales, que representan posibles soluciones al problema de optimización. En el contexto de la distribución logística,
- **Evaluación de la aptitud:** Cada colonia se evalúa en función de su aptitud para resolver el problema de optimización. En el caso de las rutas de distribución, la aptitud puede medirse en términos de la distancia total recorrida por el vehículo, el cumplimiento de las restricciones de tiempo y la eficiencia operativa.
- **Feromonas y Comunicación:** Las colonias virtuales pueden comunicarse entre sí mediante la liberación de compuestos químicos o "feromonas", que representan la calidad de la solución que representan. Las colonias que encuentran soluciones más prometedoras pueden liberar feromonas más fuertes, atrayendo a otras colonias hacia esas soluciones.
- **Selección y Reproducción:** Se seleccionan las colonias más aptas para reproducirse y generar nuevas soluciones. Este proceso puede incluir operadores de cruce y mutación para explorar nuevas áreas del espacio de soluciones y evitar la convergencia prematura hacia soluciones subóptimas.
- **Actualización de Feromonas:** Se actualizan las feromonas en función de la calidad de las soluciones encontradas por las colonias. Las soluciones más prometedoras reciben una mayor cantidad de feromonas, lo que aumenta su atracción para otras colonias en las siguientes iteraciones del algoritmo.
- **Convergencia y Terminación:** El algoritmo continúa iterando a través de estos pasos hasta que se alcanza un criterio de terminación predefinido, como un número máximo de iteraciones o una solución que cumple con cierto umbral de calidad. La convergencia hacia una solución óptima o cercana a óptima es el objetivo final del algoritmo.

En nuestro contexto del problema de optimización de rutas de distribución, las "colonias" virtuales representan posibles rutas para cada vehículo de la flota. La evaluación de la aptitud se basaría en criterios como la distancia total recorrida por el vehículo, el cumplimiento de las ventanas de tiempo de entrega y la eficiencia operativa.

Las feromonas representan la calidad de las soluciones de ruta encontradas por cada vehículo, y las colonias de vehículos pueden comunicarse entre sí para compartir información sobre las soluciones encontradas.

La selección y reproducción se utilizarían para generar nuevas soluciones de ruta combinando características de las soluciones existentes y explorando nuevas áreas del espacio de soluciones.

La actualización de feromonas se realizaría en función de la calidad de las soluciones de ruta encontradas, aumentando la atracción hacia las soluciones más prometedoras.

El algoritmo continuaría iterando hasta que se encuentre una solución que cumpla con los criterios de terminación predefinidos, como una solución que cumple con un umbral de calidad predefinido o después de un número máximo de iteraciones. El

Algoritmo de Colonias de Hongos se utilizará para resolver este problema de optimización. Se modelará el comportamiento de las colonias de hongos para buscar soluciones óptimas en el espacio de búsqueda del problema. Las "células" virtuales representarán posibles rutas de distribución, y el algoritmo evolucionará y adaptará estas células para encontrar las mejores soluciones.

10 Beneficios de Utilizar el Algoritmo de Colonias de Hongos:

- Capacidad para explorar eficazmente un amplio espacio de búsqueda.
- Adaptabilidad a cambios en las condiciones del problema.
- Capacidad para encontrar soluciones de alta calidad en problemas complejos y dinámicos.

11 Resultados Esperados:

Se espera obtener un conjunto de rutas de distribución óptimas para la flota de vehículos, que minimicen la distancia total recorrida y cumplan con todas las restricciones de tiempo y recursos. Estas rutas optimizadas permitirán a la empresa mejorar la eficiencia de su operación logística y reducir los costos operativos.

Esta descripción proporciona una visión detallada del problema a desarrollar y cómo se aplicará el Algoritmo de Colonias de Hongos para encontrar soluciones óptimas.

Referencias

1. Bidar, M & Hamidreza, K & Mouhoub, M & Sadaoui, S. (2018). *Mushroom Reproduction Optimization (MRO): A Novel Nature-Inspired Evolutionary Algorithm*. 10.1109/CEC.2018.8477837.
2. OpenAI. (2023). Chat GPT [Modelo de lenguaje GPT-3]. Recuperado de [<https://chat.openai.com/>]
3. QuadMinds. (2020, 11 agosto). *¿Sabes qué es la optimización de rutas?* <https://www.quadminds.com/blog/que-es-la-optimizacion-de-rutas>