

Algoritmo de Colonias de Hongos: Un Enfoque Bio Inspirado para la Optimización

Kevin García, Isabella Ardila & Camilo López

Ingeniería, Ciencias de la computación e inteligencia artificial

Universidad Sergio Arboleda

2 de Junio de 2024

Resumen

El mundo de la logística se ha enfrentado a problemas donde la falta de optimización de rutas conlleva a ineficiencias operativas y mayores costos. La distribución de productos se vuelve desafiante cuando no se planifican adecuadamente las rutas de entrega. Este estudio tiene como objetivo encontrar el camino más corto para una E-Commerce mensajera. Se utilizó el algoritmo bioinspirado de hongos, aplicándolo a un grafo donde se simulaban rutas mediante vértices y aristas con distintos pesos. A través de iteraciones, se evaluaron las posibles rutas para determinar la más eficiente. El estudio encontró el camino más corto para la E-Commerce mensajera utilizando el algoritmo bioinspirado de hongos aplicado a un grafo con diferentes pesos en las rutas simuladas.

Keywords: Algoritmo de colonias de hongos, algoritmo bioinspirado, optimización de rutas, grafo, optimización de recursos.

1. Introducción

El documento se enfoca en aplicar el FCA para la optimización de rutas de distribución en una red logística, entendiendo su función matemática para luego replicarlo, buscando minimizar la distancia recorrida por los vehículos y cumplir con restricciones de tiempo y recursos. Estos problemas afectan tanto a las empresas de logística como a los clientes finales, ya que se traducen en retrasos en las entregas, aumento de los costos de transporte, una utilización ineficiente de la flota de vehículos y una experiencia deficiente para los clientes. Por lo que nos enfocamos en aplicar El Algoritmo de Colonias de Hongos (FCA)

una técnica de optimización bioinspirada que emula el comportamiento de las colonias de hongos para resolver problemas de optimización. Inspirado en la búsqueda y optimización del crecimiento de los hongos en su entorno natural, este algoritmo encuentra aplicaciones en diversos campos como ingeniería, logística, telecomunicaciones y biología (Open AI, 2023). para la optimización de rutas de distribución en una red logística, buscando mejorar la eficiencia operativa y reducir costos. Este método destaca por su capacidad de exploración, adaptabilidad a cambios y la obtención de soluciones de alta calidad en entornos complejos.

Profundizamos en la aplicación del Algoritmo de Colonias de Hongos (FCA) en la optimización de rutas de distribución en una red logística. Se aborda cómo el FCA puede ser implementado para resolver el problema de encontrar las rutas más eficientes para la entrega de bienes, minimizando la distancia recorrida y reduciendo los costos operativos. Se discuten detalles técnicos sobre cómo se adaptan los conceptos de emisión de esporas, absorción de nutrientes y competencia por recursos del FCA al contexto logístico, y se presentan casos de estudio y resultados obtenidos mediante simulaciones. Además, se exploran posibles extensiones y mejoras al algoritmo para hacer frente a desafíos específicos en la optimización de rutas de distribución, como la gestión de flotas, la programación de entregas y la consideración de restricciones temporales y espaciales. Teniendo como objetivo implementar el algoritmo de Fungi y como es una herramienta efectiva para mejorar la eficiencia y reducir los costos en operaciones logísticas complejas.

2. Metodología

El Algoritmo de Colonias de Hongos (Fungal Colony Algorithm, FCA) es un método de optimización bioinspirado que se basa en el comportamiento y la estructura de las colonias de hongos para resolver problemas de optimización. Este algoritmo se inspira en la forma en que los hongos buscan y optimizan su crecimiento y desarrollo en su entorno natural (Open AI, 2023), donde el algoritmo modela este comportamiento utilizando conceptos como la emisión de esporas, la absorción de nutrientes, la comunicación entre hongos y la competencia por recursos. La optimización se logra mediante la evolución y la adaptación de las células a lo largo de varias generaciones. (Open AI, 2023).

Se pregunto a Chat GPT: explica brevemente en que consiste Fungal Colony algorithm

Así que nos enfocaremos en aplicar el FCA para resolver el problema de optimización de rutas de distribución en una red logística. El objetivo es encontrar las rutas más eficientes para entregar productos a diferentes ubicaciones, minimizando la distancia recorrida por los vehículos y cumpliendo con restricciones de tiempo y recursos.

La optimización de rutas, según QuadMinds (2020), “es el proceso por el cual se logra organizar la distribución de las entregas o repartos al cliente”. Este proceso es un desafío crucial en una empresa de distribución logística, donde se requiere la entrega de productos a diferentes ubicaciones. La empresa, que dispone de una flota de vehículos para realizar las entregas, necesita planificar las rutas de manera eficiente. El objetivo es minimizar los costos operativos, como el consumo de combustible y el tiempo de viaje, cumpliendo al mismo tiempo con las restricciones de tiempo y recursos. Por lo tanto, la optimización de rutas se convierte en una herramienta esencial para mejorar la eficiencia y la rentabilidad en el sector logístico. A continuación, veremos los diferentes aspectos que tendremos en cuenta para poder optimizar nuestro algoritmo.

Puntos de Entrega. Ubicaciones y demandas de Productos: Cada ubicación puede tener una demanda específica de productos. Es importante considerar estas demandas al planificar las rutas para asegurarse de que los vehículos lleven la cantidad adecuada de productos a cada destino.

Flota de Vehículos. Capacidad y Características: Cada vehículo en la flota tiene una capacidad máxima de carga y características únicas, como el consumo de combustible, la velocidad máxima y la autonomía. Estas características deben tenerse en cuenta al asignar vehículos a rutas específicas para maximizar la eficiencia operativa.

Restricciones de Tiempo: Ventanas de Tiempo: Además de las ventanas de tiempo para las entregas en los puntos de entrega individuales, también puede haber restricciones de tiempo para la duración total de las rutas. Por ejemplo, es posible que se requiere que todas las entregas se realicen dentro de un cierto período de tiempo para evitar retrasos excesivos.

Costos Operativos: Consumo de Combustible y Desgaste de Vehículos: Minimizar la distancia total recorrida por la flota de vehículos no solo reduce los costos de combustible, sino que también ayuda a minimizar el desgaste de los vehículos, lo que a su vez reduce los costos de mantenimiento a largo plazo.

Tiempo de Viaje y Eficiencia: Reducir el tiempo de viaje total también contribuye a la eficiencia operativa general de la empresa, permitiendo una entrega más rápida de productos a los clientes y una mejor planificación de recursos.

Objetivo de la Optimización: El objetivo final de la optimización es encontrar un conjunto de rutas de distribución que minimicen la distancia total recorrida por la flota de vehículos, cumpliendo al mismo tiempo con todas las restricciones de tiempo y recursos establecidas. Esto garantizará una operación logística eficiente y rentable para la empresa de distribución.

Aplicación del Algoritmo de Colonias de Hongos:

El algoritmo de Colonias de Hongos (FCA) nos ayuda a resolver nuestro objetivo que es la optimización de rutas de distribución en la empresa de logística para minimizar la distancia total recorrida por un conjunto de camiones que visitan un conjunto de puntos de entrega.

Por otro lado, la optimización de la Reproducción de Hongos (MRO por sus siglas en inglés) inspirado y motivado por los mecanismos de reproducción y crecimiento de los hongos en la naturaleza (Bidar M, 2018). Para lograrlo vamos a usar las diferentes fases de este algoritmo teniendo nuestros parámetros M , que es el número de hongos y N el número de distribuciones de esporas por los hongos padres.

Esto se puede resolver, pero tenemos ciertas restricciones como:

- Cada punto de entrega debe visitarse una vez.
- La capacidad de cada camión es limitada.
- La duración de cada viaje no debe superar un límite establecido

Para lograrlo vamos usar las diferentes fases del algoritmo MRO teniendo nuestros parámetros M , que es el número de hongos y N el número de distribución de esporas por los hongos padres.

Fase 1 - Inicialización: Utilizamos grafos para representar soluciones en la optimización de rutas. La inicialización implica establecer todas las posibles rutas en una red de puntos de entrega, según el número de colonias de hongos (parámetro M). M se interpreta como la cantidad de soluciones posibles, es decir, todas las rutas potenciales desde un punto A hasta un punto B. Dado que las rutas se pueden representar como caminos en un grafo, donde los nodos son los puntos de interés y las aristas son los tramos de carretera entre ellos, el número total de rutas posibles puede ser muy grande y modelarse como un problema de combinatoria.

Cada colonia de hongos en el algoritmo representa

una posible ruta desde el punto de partida hasta el destino. El parámetro M controla la cantidad de rutas consideradas durante la optimización, influyendo en la diversidad y exploración en la búsqueda de la mejor ruta. Por ejemplo, si $M = 10$, se evalúan 10 soluciones diferentes, cada una representada por una colonia de hongos. Este enfoque heurístico permite una exploración eficiente del espacio de soluciones.

El parámetro N determina el número de modificaciones consideradas para cada ruta. Un mayor valor de N permite explorar más opciones, encontrando soluciones óptimas en términos de costos y tiempos de entrega. Sin embargo, un valor más alto de N aumenta el costo computacional del algoritmo.

Es sabido que la función de fitness es una de las componentes principales de los Algoritmos Genéticos. Ésta es la que permite decidir que individuos continúan en la población y cuales expiran, se trata de una función evaluadora de la calidad de un individuo como solución a nuestro problema (library, s.f.). En la optimización de rutas logísticas, esta función se adapta a variables como tiempo de viaje, costos y penalizaciones por incumplimiento. Evalúa la calidad de las soluciones, guiando la selección de individuos para la reproducción y próxima generación del algoritmo, con el objetivo de mejorar la eficiencia y efectividad de las rutas.

Fase 2 - Búsqueda local (Reproducción local):

la búsqueda local, expande las soluciones explorando vecindarios cercanos a las rutas principales. Cada colonia genera nuevas posibilidades, explorando variaciones de las rutas existentes.

Parámetros:

- r - Radio de la búsqueda/reproducción local
- c - Decidir si una colonia se elimina o no

Generación de nuevas soluciones (esporas):

$$X_{ij} = X_i^{parent} + Rand(-r, r) \quad (1)$$

- X_{ij} : Posición de la espora j en la colonia i
- X_i^{parent} : Posición de la ruta principal de la colonia i .

- r : Radio de búsqueda local alrededor de la ruta principal actual

Interpretación: En esta fase, cada colonia de hongos (representando una solución) genera N nuevas soluciones (esporas) en el vecindario de su ruta principal actual. Cada nueva solución se obtiene sumando un desplazamiento aleatorio alrededor de la posición de la ruta principal actual, lo que permite explorar diferentes posibles rutas en el vecindario.

1. X_{ij} : Representa la posición de una nueva espora, es decir, una posible solución alternativa dentro del espacio de búsqueda local. En el contexto de nuestro problema cada X_{ij} representa una ruta potencialmente diferente que difiere
2. Ligeramente de la ruta principal (representada por X_i^{parent}). Por ejemplo, X_{ij} podría representar una ruta que toma un camino alternativo en una intersección o realiza una entrega en un orden diferente.
3. X_i^{parent} : Representa la posición del hongo padre, que a su vez representa la solución o la ruta principales de una colonia de hongos.
4. $Rand(-r,r)$ genera valores aleatorios en un radio de búsqueda local para introducir variabilidad. Encontrando soluciones cercanas a la ruta principal y evita quedar atrapado en óptimos locales subóptimos. El radio de búsqueda determina qué tan lejos exploramos nuevas permitiendo explorar diferentes variaciones de la ruta, como caminos alternativos, cambios en el orden de las paradas, etc.

El parámetro c en el FCA se utiliza para decidir si se elimina o no una colonia (o conjunto de soluciones) en función de su calidad en relación con el resto de las colonias, como a su vez se utiliza junto con el promedio de aptitud de la colonia y el promedio total de aptitud de todas las colonias en la iteración actual. La condición de eliminación se define de la siguiente manera:

$$Avg(i) + Tavg * c < Tavg \quad (2)$$

Donde:

- $Avg(i)$ es el promedio de aptitud de la colonia i .
- $Tavg$ es el promedio total de aptitud de todas las colonias en la iteración actual
- c es el parámetro que controla la eliminación de colonias.

Esta condición compara el promedio de aptitud de una colonia con un factor c añadido, con el promedio total de todas las colonias. Si el promedio de la colonia es menor que el promedio total, se considera de baja calidad y puede ser eliminada. Esto ayuda a centrarse en soluciones de mayor calidad y mejorar la eficiencia de la búsqueda.

En nuestro contexto, el parámetro c se asocia con la capacidad de adaptación de cada ruta propuesta a las condiciones específicas del problema. Aquí exponemos una manera de relacionarlo con nuestro caso:

El parámetro ' c ' actúa como un umbral para determinar la competitividad de una ruta en comparación con otras. Si la aptitud promedio de una ruta es significativamente menor que el promedio general multiplicado por ' c ', esa ruta se considera de baja calidad y podría ser eliminada. Esto permite enfocar los esfuerzos en rutas más prometedoras. Un valor bajo de ' c ' aumenta la exploración de nuevas soluciones, mientras que uno alto favorece la explotación de soluciones conocidas. Esta flexibilidad se adapta a las necesidades del problema de optimización de rutas logísticas.

$$X_{ij} = X_i^{parent} + Mov_j^{wind} \quad (3)$$

Interpretación: Genera nuevas posibles rutas de entrega en el vecindario de la ruta principal actual, teniendo en cuenta tanto las soluciones actuales como la influencia global adicional para mejorar su eficiencia

- X_{ij} : Representa una posible ruta alternativa para la entrega de los productos desde la ubicación i hasta la ubicación j . Como resultado es la mejor ruta posible, teniendo menor tiempo a la hora de entrega y menos recursos consumidos.
- X_i^{parent} : Representa la posición del hongo padre, que a su vez representa la solución o la ruta principal de una colonia de hongos. En nuestro problema, representa la ruta principal que se está explorando en la búsqueda local, es la base desde la cual se generan las esporas (nuevas soluciones potenciales).
- Mov_j^{wind} : Representa la posición del hongo padre, que a su vez es la solución o la ruta principal de una colonia de hongos. En nuestro problema, es la ruta principal que se está explorando en la búsqueda local, la base desde la cual se generan las esporas (nuevas soluciones potenciales).

Durante la fase de búsqueda local, se generan nuevas soluciones dentro del vecindario de las soluciones principales actuales, representadas por X_{ij} . Estas soluciones alternativas se diferencian ligeramente de la ruta principal actual (X_i^{parent}), pudiendo implicar cambios como tomar caminos alternativos o ajustar los horarios de entrega. El Mov_j^{wind} introduce variabilidad y exploración al permitir que las nuevas soluciones se generen en ubicaciones dentro de un radio alrededor de la ruta principal actual. Este proceso es esencial para evitar óptimos locales subóptimos, ya que amplía la exploración del espacio de búsqueda y permite descubrir soluciones potencialmente mejores.

Fase 3: Búsqueda global (Búsqueda global con viento)

$$Mov_j^{wind} = (X_i^* - X_k^*) * \left(\frac{Avg(i)}{T_{avg}} \right)^{-m} * Rand(-\alpha, \alpha) * rs + Rand(-r, r) \quad (4)$$

Interpretación:

- Esta ecuación calcula el movimiento inducido por el viento en la dimensión j del espacio de búsqueda.
- X_i^* y X_k^* representan las mejores soluciones en las colonias i y k respectivamente, actuando como puntos de referencia para el movimiento del viento.
- $Avg(i)$ es el promedio de las medidas de aptitud de todas las soluciones en la colonia i , y T_{avg} es el promedio global de todas las medidas de aptitud.
- m controla la magnitud del movimiento del viento.
- $Rand(=\alpha, \alpha)$ y $Rand(=r, r)$ introducen componentes aleatorios en la dirección y magnitud del movimiento del viento.
- rs y α son parámetros que controlan la escala y magnitud máxima del componente aleatorio del movimiento del viento, respectivamente.

Las mejores soluciones locales en cada colonia representan las rutas más prometedoras hasta ahora, mientras que el promedio global de aptitudes da una referencia general del rendimiento de las rutas.

El viento, $(X_i - X_k) \times (Avg(i)/T_{avg})$, se basa en la diferencia entre las mejores soluciones locales y el promedio global de aptitudes, dirigiendo las rutas hacia áreas más ventajosas. La introducción de componentes aleatorios, $m \times Rand(-s, s) \times rs + Rand(-r, r)$, en el movimiento del viento permite explorar diversas áreas del espacio de búsqueda de manera controlada, evitando soluciones locales subóptimas en la búsqueda de rutas de distribución óptimas.

Algoritmo MRO:

- **Inialización:** La fase en la que se generan aleatoriamente las soluciones iniciales (colonias de hongos) en el espacio de búsqueda.

- **Búsqueda Local (Reproducción Local):** La fase en la que se generan nuevas soluciones (esporas) en el vecindario de las soluciones principales actuales.

- **Búsqueda Global (Búsqueda Global con Viento):** La fase en la que se introduce el viento como una fuerza global adicional que afecta a todas las soluciones en todas las colonias.

Problema de Optimización de Rutas:

- **Soluciones Iniciales:** Representan las rutas iniciales generadas aleatoriamente para los vehículos.
- **Nuevas Soluciones (Esporas):** Representan las posibles rutas que se generan cerca de las rutas principales actuales, explorando el vecindario del espacio de búsqueda.
- **Viento:** Representa la influencia adicional que afecta a las rutas, moviéndolas hacia regiones potencialmente prometedoras del espacio de búsqueda.

Comentarios adicionales:

- El algoritmo MRO utiliza ecuaciones adaptadas al problema de optimización de rutas en cada fase.
- Genera posibles rutas evaluadas por una función de aptitud (por ej., minimizando la distancia total).
- La búsqueda continúa en múltiples iteraciones hasta cumplir un criterio de terminación.
- Emplea exploración global y local para encontrar soluciones óptimas o subóptimas.

Exploración del Espacio de Soluciones: FCA es capaz de explorar de manera eficiente un amplio espacio de soluciones. En el contexto de la planificación de rutas de distribución, esto significa que puede considerar una variedad de posibles rutas para cada vehículo, teniendo en cuenta las diferentes combinaciones de puntos de entrega y ventanas de tiempo, y evaluar su viabilidad y eficiencia.

Función Objetivo Para Minimizar Tiempo y Distancia.

$$\text{Minimize} \sum_{i=1}^V \sum_{j=1}^{N_i-1} (\text{dist}(c_{ij}, c_{i(j+1)}) / \text{velocidad}) \quad (5)$$

Donde:

- V es el número de vehículos disponibles.
- N_i es el número de clientes atendidos por el vehículo i .
- c_{ij} es el cliente j atendido por el vehículo i
- $\text{dist}(x,y)$ es la distancia euclidiana entre los puntos x e y .
- velocidad es la velocidad promedio del vehículo, que se utiliza para convertir la distancia en tiempo.

Esta función objetivo calcula el tiempo total de viaje para todos los vehículos, minimizando la suma de los tiempos de viaje individuales. Es adecuada para minimizar el tiempo y la distancia total recorrida por los vehículos, sin considerar otras restricciones como capacidad del vehículo o ventanas de tiempo de los clientes.

Una empresa de mensajería de comercio electrónico ha contratado a nuestra empresa de consultoría para revisar y mejorar sus operaciones de entrega de última milla. Si bien la empresa ya utiliza software de optimización de rutas para encontrar las rutas de entrega más cortas para todos sus conductores, ahora buscan obtener más información a partir de los datos que rastrean en las operaciones de entrega de última milla. Han generado algunas ideas sobre las características de la operación de entrega en sí y por eso han enviado un resumen de datos de las entregas recientes en el archivo denominado "lastMile-DeliveryTimes.csv". En este archivo .csv, encontraremos un conjunto de datos que describe una cantidad ($N=1000$) de entregas a domicilio realizadas por la empresa. A continuación se proporciona una visión de los datos que son de ayuda para construir los grafos que nos sirvan como mapeo, las variables claves son:

- **DeliveryTime:** tiempo transcurrido desde la salida del mensajero del centro de distribución de comercio electrónico hasta la llegada a la ubicación del cliente, "Para optimizar las rutas con base en el tiempo de entrega". (horas)

- **NumberPackagesDelivered:** Indica el número de paquetes entregados por el mensajero en su ruta diaria. "Para tener en cuenta la carga del mensajero".
- **DistanceToCityCenterFromDC:** La distancia desde el centro de distribución de comercio electrónico hasta el centro de la ciudad principal más cercano, que es el destino principal de las entregas. "Para considerar la distancia en la optimización"
- **VehicleType:** Indica si el vehículo de entrega es eléctrico o de gas, lo que puede influir en su fiabilidad y desempeño.
- **FulfillmentChannel:** Representa la fuente de inventario para la entrega a domicilio, "Para entender el origen del inventario y su proximidad"

Consideraciones para realizar el grafo.

Se construye un grafo dirigido usando NetworkX para modelar las entregas. En este grafo, cada nodo representa una entrega y cada arista representa las posibles rutas entre las entregas. Los pesos de las aristas se basan en factores como la distancia y el tiempo de entrega. A los nodos se les asignan atributos relevantes como el tiempo de entrega, el número de paquetes, la distancia al centro de la ciudad, el tipo de vehículo y el canal de cumplimiento.

3. Resultados

Construcción del grafo.

Construimos un grafo con ubicaciones y rutas, ponderado por factores como distancia y tiempo. Usando MRO para optimizar rutas, mejorando la eficiencia en entregas de última milla.

- Utilizando los datos proporcionados, construimos un grafo donde los nodos representen ubicaciones específicas y las aristas representen las rutas posibles entre estas ubicaciones.

- Utilizamos los atributos de los nodos y las aristas para calcular los pesos de las aristas, teniendo en cuenta factores como la distancia, el tiempo de viaje estimado, las condiciones climáticas, etc. Esto lo podemos ver implementado en la figura 1.
- Luego, utilizamos el algoritmo bio-inspirado de la colonia de hongos en su enfoque de optimización para evaluar los resultados. Que se hace de la siguiente manera:

Figura 1

Grafo con pesos y aristas

Construcción de caminos:

Para cada hongo i , se construye un camino X_i desde el nodo inicial hasta el nodo final. Este camino se representa como una secuencia de movimientos entre nodos, donde X_{ij} indica que el hongo i se mueve del nodo j al nodo i .

Selección de movimientos:

En cada paso de la construcción del camino, el hongo i selecciona aleatoriamente un vecino no visitado j como el próximo nodo a visitar. Matemáticamente, esto se puede expresar como:

$$X_{ij} = \begin{cases} 1 & \text{si el hongo } i \text{ se mueve de } j \text{ a } i \\ 0 & \text{en otro caso} \end{cases}$$

Cálculo de la distancia del camino:

Una vez que se ha construido el camino X_i para cada hongo, se calcula la distancia total del camino sumando los pesos de las aristas en el camino. Matemáticamente, esto se puede expresar como:

$$\text{Distancia}(X_i) = \sum_{j=1}^{N-1} X_{ij} \cdot \text{Peso}_{ij}$$

Actualización del mejor camino:

En cada iteración, se selecciona el camino más corto entre todos los caminos construidos por los hongos. Si este camino es más corto que el mejor camino encontrado hasta el momento, se actualiza el mejor camino con este nuevo camino más corto. Esto se puede modelar matemáticamente como:

$$X^* = \arg \min_{X_i} \{\text{Distancia}(X_i)\}$$

El algoritmo se puede modelar matemáticamente utilizando variables binarias para representar los movimientos de los hongos entre nodos, y luego utilizando estas variables para calcular la distancia total del camino y seleccionar el mejor camino entre todos los caminos construidos por los hongos en cada iteración.

Finalmente, luego de varias iteraciones hemos logrado encontrar una solución altamente eficiente. El camino más corto encontrado, representado por las entregas en el siguiente orden: [0 ->3 ->1 ->2 ->4], **tiene una distancia total de 7.1 unidades.** Esto significa que nuestros mensajeros pueden seguir esta ruta para entregar los paquetes de manera rápida y eficiente, minimizando los tiempos de entrega y optimizando nuestros recursos operativos.

Este resultado demuestra el potencial de los enfoques bioinspirados para resolver problemas complejos en el ámbito empresarial. Al aprovechar algoritmos como el de Hongos Simplificado, podemos mejorar significativamente nuestras operaciones de entrega y proporcionar un servicio excepcional a nuestros clientes, aumentando así la satisfacción del cliente y la eficiencia general de nuestra empresa de mensajería.

4. Conclusión

Este estudio ha demostrado la eficacia del Algoritmo de Optimización de la Reproducción de Hongos (MRO) en la optimización de rutas logísticas. La representación de las rutas mediante grafos permitió evaluar de manera detallada las posibles soluciones en términos de tiempo y costo de entrega. La fase de búsqueda local facilitó la generación de nuevas

rutas en el vecindario de las soluciones principales, mientras que la búsqueda global, influenciada por el "viento", permitió una exploración más amplia y la evitación de óptimos locales subóptimos.

El uso de datos específicos, como el tiempo de entrega, el número de paquetes entregados, la distancia al centro de la ciudad, el tipo de vehículo y el canal de cumplimiento, permitió construir un grafo ponderado que representaba con precisión las entregas. Este enfoque llevó a la identificación de rutas altamente eficientes, mejorando significativamente las operaciones de entrega de última milla.

En síntesis, el algoritmo MRO ha demostrado ser una herramienta valiosa para resolver problemas complejos de optimización de rutas, mejorando la eficiencia operativa y la satisfacción del cliente en la empresa de mensajería.

Referencias (APA)

- [1] OPENAI (2023), *Chat GPT [Modelo de lenguaje GPT-3]*. Recuperado de [\[https://chat.openai.com/\]](https://chat.openai.com/)
- [2] Bidar, M & Hamidreza, K & Mouhoub, M & Sadaoui, S. (2018). *Mushroom Reproduction Optimization (MRO): A Novel Nature-Inspired Evolutionary Algorithm*. 10.1109/CEC.2018.8477837. <http://www.cdt21.com/resources/guide3.asp>
- [3] QuadMinds. (2020, 11 agosto). *¿Sabes qué es la optimización de rutas?* <https://www.quadminds.com/blog/que-es-la-optimizacion-de-rutas>
- [4] Library (s. f.). *Fitness* <https://1library.co/article/fitness-algoritmos-gen>